

ชื่อ-นามสกุล	นาย อรรถพล ศรีม่วง
รหัสบัตร	67160242
วันที่ส่ง	05/08/2569

1.ระบุปัญหาที่พบอย่างน้อย 5 ปัญหา และจับคู่กับมิติ Data Quality อย่างน้อย 3 มิติ

ปัญหาที่พบ	คอลัมน์	มิติ Data Quality	หลักฐาน/จำนวนแถว														
รายการสั่งซื้อซ้ำซ้อน	Transaction_ID และทุกคอลัมน์	Uniqueness	พบแถวซ้ำ 18 แถว memory usage: /8.9+ KB np.int64(18)														
ข้อมูลขาดหาย	Customer_Email, Province	Completeness	Customer_Email หาย 50 แถว , Province หาย 12 แถว ... === 2. Missing Values Per Column === Missing_Count <table><tr><td>Transaction_ID</td><td>0</td></tr><tr><td>Customer_ID</td><td>0</td></tr><tr><td>Customer_Name</td><td>0</td></tr><tr><td>Customer_Email</td><td>50</td></tr><tr><td>Gender</td><td>0</td></tr><tr><td>Province</td><td>12</td></tr><tr><td>Order_Date</td><td>0</td></tr></table>	Transaction_ID	0	Customer_ID	0	Customer_Name	0	Customer_Email	50	Gender	0	Province	12	Order_Date	0
Transaction_ID	0																
Customer_ID	0																
Customer_Name	0																
Customer_Email	50																
Gender	0																
Province	12																
Order_Date	0																
สะกดรูปแบบข้อความไม่เป็นมาตรฐาน	Gender, Payment_Method, Order_Status	Consistency	Gender มี 10 รูปแบบ เช่น MALE, M, f, Payment_Method มี 14 รูปแบบ, Order_Status มี 7 รูปแบบ														
รูปแบบวันที่ผิดและ	Order_Date	Validity	ผสมฟอร์แมต YYYY-MM-DD / MM/DD/YYYY และพบค่าผิดปกติ เช่น 31/02/2026, 2026-13-05, not_a_date														

ปัญหาที่พบ	คอลัมน์	มิติ Data Quality	หลักฐาน/จำนวนแถว																																													
เป็นไปไม่ได้																																																
ตัวเลขผิดปกติและคำนวณยอดเงินไม่ถูกต้อง	Quantity, Transaction_Amount	Accuracy	Quantity ติดลบ -3 และพิมพ์ผิดสเกล (99), Transaction_Amount มีค่าติดลบ (-500) และค่าคัมมีระบบ (999999) ยอดเงินไม่ตรงตามสูตร <table><thead><tr><th></th><th>Quantity</th><th>Unit_Price</th><th>Discount_Rate</th><th>Transaction_Amount</th></tr></thead><tbody><tr><td>count</td><td>630.000000</td><td>630.000000</td><td>630.000000</td><td>630.000000</td></tr><tr><td>mean</td><td>3.660317</td><td>227.080365</td><td>0.061746</td><td>6092.293000</td></tr><tr><td>std</td><td>4.184784</td><td>126.984729</td><td>0.066935</td><td>66925.290163</td></tr><tr><td>min</td><td>-3.000000</td><td>37.360000</td><td>0.000000</td><td>-500.000000</td></tr><tr><td>25%</td><td>2.000000</td><td>137.095000</td><td>0.000000</td><td>316.190000</td></tr><tr><td>50%</td><td>3.000000</td><td>198.935000</td><td>0.050000</td><td>579.600000</td></tr><tr><td>75%</td><td>5.000000</td><td>298.615000</td><td>0.100000</td><td>1037.892500</td></tr><tr><td>max</td><td>99.000000</td><td>779.430000</td><td>0.200000</td><td>999999.000000</td></tr></tbody></table>		Quantity	Unit_Price	Discount_Rate	Transaction_Amount	count	630.000000	630.000000	630.000000	630.000000	mean	3.660317	227.080365	0.061746	6092.293000	std	4.184784	126.984729	0.066935	66925.290163	min	-3.000000	37.360000	0.000000	-500.000000	25%	2.000000	137.095000	0.000000	316.190000	50%	3.000000	198.935000	0.050000	579.600000	75%	5.000000	298.615000	0.100000	1037.892500	max	99.000000	779.430000	0.200000	999999.000000
	Quantity	Unit_Price	Discount_Rate	Transaction_Amount																																												
count	630.000000	630.000000	630.000000	630.000000																																												
mean	3.660317	227.080365	0.061746	6092.293000																																												
std	4.184784	126.984729	0.066935	66925.290163																																												
min	-3.000000	37.360000	0.000000	-500.000000																																												
25%	2.000000	137.095000	0.000000	316.190000																																												
50%	3.000000	198.935000	0.050000	579.600000																																												
75%	5.000000	298.615000	0.100000	1037.892500																																												
max	99.000000	779.430000	0.200000	999999.000000																																												

2.อธิบายว่าเหตุใดการใช้ dropna() กับ Customer_Email อาจทำให้ยอดขายรวมใน Data Warehouse ผิดเพี้ยน และเหตุใดการเติมค่าเฉลี่ยจึงไม่เหมาะกับข้อมูลประเภทอีเมล

ตอบ เหตุผลที่การใช้ dropna() กับ Customer_Email ทำให้ยอดขายรวมผิดเพี้ยน

- สูญเสียรายการธุรกรรมใน Data Warehouse แถวข้อมูลแต่ละแถวคือตารางข้อเท็จจริง ที่บันทึกยอดขาย หากสั่งลบแถว (dropna()) เพียงเพราะคอลัมน์อีเมลเป็นค่าว่าง ยอดขายของธุรกรรมนั้นจะหายไปจากระบบทันที

เหตุผลที่การเติมค่าเฉลี่ย (Mean Imputation) ไม่เหมาะสมกับข้อมูลอีเมล

- ชนิดข้อมูลไม่รองรับ ค่าเฉลี่ยที่เป็นสถิติเชิงพรรณนาที่คำนวณได้เฉพาะกับข้อมูลเชิงปริมาณที่เป็นตัวเลข เช่น รายได้ หรือ จำนวนชิ้น ไม่สามารถนำตัวอักษรสตริงของอีเมลมาหาผลรวมและหารเพื่อหาค่าเฉลี่ยได้
- อีเมลเป็นข้อมูลระบุตัวตนการนำค่าทางสถิติใดๆ มาเติม จะทำลายความถูกต้องของมิติตัวตน และทำให้การเชื่อมโยงข้อมูลลูกค้าผิดพลาด

3.ยกตัวอย่าง 1 วันที่สามารถตีความได้ทั้ง DD/MM/YYYY และ MM/DD/YYYY แล้วอธิบายว่าคุณใช้หลักฐานใดช่วยตัดสิน

ตอบ วันที่ตัวอย่าง 05/04/2025

- ตีความแบบ DD/MM/YYYY วันที่ 5 เมษายน 2025
- ตีความแบบ MM/DD/YYYY วันที่ 4 พฤษภาคม 2025

หลักฐานและตรรกะที่ใช้ตัดสิน

1. เปรียบเทียบกับ Load_Timestamp

- ตรรกะวันที่ทำการการต้องเกิดขึ้นก่อนหรือพร้อมกับวันที่บันทึกข้อมูลเข้าระบบเสมอ
- การตัดสิน: หาก Load_Timestamp ของแถวนี้บันทึกไว้ ณ วันที่ 2026-04-15
 - การแปลงเป็น 2026-05-04 (MM/DD/YYYY) จะเป็นข้อมูลอนาคต ซึ่งเป็นไปไม่ได้ในทางธุรกิจ
 - จึงสรุปได้ทันทีว่าเป็นวันที่ 2026-04-05 (DD/MM/YYYY)

2. ตรวจสอบ Dominant Format จากแถวที่ไม่กำกวม

- ตรรกะ ตรวจสอบรูปแบบวันที่ในคอลัมน์เดียวกันของแถวอื่นที่มีตัวเลขมากกว่า 12 ในตำแหน่งแรกหรือตำแหน่งกลาง
- การตัดสิน หากพบค่าเช่น 25/04/2026 หรือ 18/03/2026 จำนวนมากในไฟล์ เป็นหลักฐานยืนยันว่าไฟล์ต้นทางนี้สร้างขึ้นบนระบบที่ใช้ฟอร์แมต DD/MM/YYYY เป็นมาตรฐานหลัก

3. ลำดับเวลาธุรกรรมของลูกค้า (Customer Chronological Sequence)

- ตรรกะ เปรียบเทียบกับประวัติออเดอร์ก่อนหน้าและถัดไปของ Customer_ID เดียวกัน
- การตัดสิน หากลูกค้ามีออเดอร์ก่อนหน้าเมื่อวันที่ 2026-04-02 และมีออเดอร์ถัดไปเมื่อวันที่ 2026-04-10 วันที่ 2026-04-05 จะสอดคล้องกับลำดับเวลาจริงมากกว่าวันที่ 2026-05-04

4.รายการที่ Transaction_Amount ไม่ตรงกับสูตรควรแก้ไขทุกแถวหรือไม่? ให้อธิบายผล
ของ Is_Promotion ต่อการตัดสินใจ

ควรคำนวณและปรับปรุงแก้ไขทุกแถว ที่ยอดเงินไม่ตรงตามสูตร เพื่อรักษาความถูกต้องของตัวเลขทางการเงิน
ใน Fact Table แต่ต้องดำเนินการผ่านตรรกะการตรวจสอบและบันทึก Audit Flag เสมอ

1. เหตุผลที่ต้องแก้ไขทุกแถวที่ยอดเงินไม่ตรง

- ความถูกต้องของยอดขาย ถูกนำไปใช้คำนวณเชิงสถิติ เช่น ยอดขายรวมและรายได้เฉลี่ย การปล่อยให้มีค่าผิดปกติ เช่น ค่าติดลบ 500, ค่าคัมมี 999999 หรือสเกลผิด 19,610.76 แทนที่จะเป็น 1,508.52 จะส่งผลให้รายงานผู้บริหารคลาดเคลื่อนอย่างรุนแรง
- ใช้หลักการ Recalculate + Flagging แทนการลบแถวทิ้ง (ซึ่งทำให้จำนวนธุรกรรมหาย) ให้ปรับแก้คอลัมน์ Transaction_Amount ใหม่พร้อมติด Accuracy_Flag = True ไว้ตรวจสอบย้อนหลัง

2. ผลของ Is_Promotion ต่อการตัดสินใจ

- ยืนยันประเภทข้อผิดพลาด
 - กรณี Is_Promotion = 'Y' ช่วยยืนยันว่าออเดอร์นี้ตั้งใจให้มีส่วนลดจริง หากยอดเงินผิดเพี้ยนไปจากสูตร มักเกิดจากข้อผิดพลาดของระบบบันทึกข้อมูล ปรับแก้ตามสูตรจึงปลอดภัยและตรงตามวัตถุประสงค์ทางธุรกิจ
 - กรณี Is_Promotion = 'N' แต่มี Discount_Rate > 0 ชี้ให้เห็นปัญหาความไม่สอดคล้องของข้อมูล ส่งผลให้ต้องปรับแก้ไขยอดเงินตามส่วนลดจริง พร้อมทั้งอัปเดตสถานะโปรโมชั่นให้ถูกต้อง
- คัดกรองข้อมูลสำหรับประเมินผลแคมเปญ Flag Is_Promotion = 'Y' เป็นมิติสำคัญในการวิเคราะห์ผลตอบแทนจากการลงทุน (ROI) การรักษาแถวข้อมูลเหล่านี้ไว้โดยไม่ลบทิ้ง ช่วยให้ทีมการตลาดประเมินประสิทธิภาพแคมเปญได้อย่างแม่นยำ

5.เพราะเหตุใดข้อมูลที่อยู่นอก IQR Bound จึงไม่จำเป็นต้องเป็นข้อมูลผิดเสมอ? ยกตัวอย่างจาก Dataset นี้

เหตุผลที่ Outliers ไม่จำเป็นต้องเป็นข้อมูลผิด

- ขาดบริบททางธุรกิจ สถิติแบบ IQR ไม่เข้าใจความแตกต่างของสเกลราคาสินค้า เช่น สินค้าหมวดอิเล็กทรอนิกส์ย่อมมีราคาสูงกว่าอาหารหรือเครื่องแต่งกาย
- พฤติกรรมการซื้อจริงแบบลูกค้าบางรายอาจสั่งซื้อสินค้าปริมาณมากในออเดอร์เดียวเพื่อนำไปขายต่อ ซึ่งเป็นพฤติกรรมปกติทางการค้า

ตัวอย่างเปรียบเทียบจาก Dataset นี้ (Upper Bound = 2,101.70 บาท)

ประเภท Outlier	ตัวอย่าง Transaction	รายละเอียดข้อมูล	การวิเคราะห์บริบท
ข้อมูลถูกต้อง (Legitimate)	T000095	หมวด Electronics Quantity = 6 Unit_Price = 571.14 ยอดขาย = 3,426.84 บาท	เหตุผลจริง ราคาต่อหน่วยและจำนวนขึ้นสมเหตุสมผล เป็น การซื้ออุปกรณ์ไอที 6 ชิ้น การลบทังจะทำให้ยอดขายรวมของบริษัทขาดหาย
ข้อมูลถูกต้อง (Legitimate)	T000403	หมวด Home Quantity = 5 Unit_Price = 776.68 (ส่วนลด 10%) ยอดขาย = 3,495.06 บาท	เป็นการซื้อเฟอร์นิเจอร์และของใช้ในบ้านราคาน่าเชื่อถือ
ข้อมูลผิดพลาด (Data Error)	T000355	หมวด Electronics Quantity = 99 Unit_Price = 286.94 ยอดขาย = 28,407.06 บาท	ข้อผิดพลาดของ จำนวนสั่งซื้อ 99 ชิ้นเกิดจากการคีย์ข้อมูลผิดสเกล ไม่อยู่ในช่วงปกติ 1-20 ชิ้น

ประเภท Outlier	ตัวอย่าง Transaction	รายละเอียดข้อมูล	การวิเคราะห์บริบท
ข้อมูลผิดพลาด (Data Error)	T000386	Transaction_Amount = 999,999 บาท	ข้อผิดพลาดของค่า Sentinel/Dummy Value ที่ ระบบสตรีมข้อมูลบันทึกค้างไว้

Reflection

1.ขั้นตอนใดมีความเสี่ยงทำให้ข้อมูลจริงสูญหายมากที่สุด?

ขั้นตอนการลบข้อมูลและการจัดการ Outliers มีความเสี่ยงทำลายข้อมูลจริงมากที่สุด โดยเฉพาะการลบแถวทิ้งโดยพิจารณาเพียงสถิติล้วน ๆ โดยไม่สนใจบริบททางธุรกิจ

2.กฎใดควรนำไปทำ Automation ใน Data Pipeline?

กฎการตรวจสอบความถูกต้องเชิงตรรกะและโครงสร้าง เช่น การตรวจสอบคอลัมน์สำคัญห้ามเป็นค่าว่าง การทำ Recalculation ให้เป็นมาตรฐานพร้อมติด Audit Flag เมื่อพบข้อมูลผิดปกติ

3.หากใช้ Great Expectations คุณจะสร้าง Expectation ได้อย่างน้อย 3 ข้อ?

- `expect_column_values_to_not_be_null(column="Transaction_ID")` เพื่อรับประกันว่าคีย์หลักของ Fact Table สมบูรณ์ 100%
- `expect_column_values_to_be_between(column="Quantity", min_value=1, max_value=20)` เพื่อควบคุมปริมาณการสั่งซื้อให้อยู่ในขอบเขตธุรกิจจริง
- `expect_column_values_to_be_in_set(column="Order_Status", value_set=["Pending", "Completed", "Cancelled", "Returned", "Unknown"])` เพื่อบังคับใช้กรอบค่ามาตรฐานของสถานะคำสั่งซื้อก่อนเข้า Data Warehouse